
Classification audio multi-label sans réseau de neurones entraîné

Features manuelles contre embeddings pré-entraînés sur les
sons d'espèces du Pantanal (BirdCLEF + 2026)

Anaïs Azouaoui

Mai 2026

Table des matières

1	Introduction, contexte et problématique	1
2	Analyse des données	1
2.1	Composition taxonomique et couverture	1
2.2	Déséquilibre et métadonnées	2
2.3	Géographie et représentativité spatiale	2
2.4	Propriétés audio	3
2.5	Soundscapes et domain gap	4
2.6	Des observations aux décisions	5
3	Méthode proposée	7
3.1	Découpage temporel : la fenêtre de cinq secondes	7
3.2	Caractéristiques et représentations	7
3.3	Rappel sur les classifieurs employés et justification	7
3.4	Protocole de validation	8
3.5	Décisions d’entraînement et d’évaluation	8
4	Résultats	8
4.1	Comparaison des classifieurs	9
4.2	Réglage et analyse des hyperparamètres	9
4.3	Analyse critique : domain gap et conditions réelles	10
4.4	Métriques complémentaires	11
5	Extensions et analyses complémentaires	11
5.1	Comparaison avec un modèle pré-entraîné	11
5.2	Réduction du domain gap par pseudo-labeling	12
5.3	Réduction du domain gap par augmentation de bruit ambiant	12
5.4	Analyse des cas d’erreurs par espèce	13
6	Conclusion	14
7	Bibliographie	14
A	Figures complémentaires d’exploration	15

1 Introduction, contexte et problématique

Le déclin rapide de la biodiversité impose de surveiller les populations animales sur de vastes territoires et sur de longues périodes, une échelle hors de portée de l’observation humaine directe. Le suivi acoustique passif répond à ce besoin : des enregistreurs autonomes laissés sur le terrain captent en continu le paysage sonore, dont les vocalisations animales constituent un indicateur de présence. Toutefois, la masse d’enregistrements produite dépasse de loin ce qu’un expert peut écouter à l’oreille. Identifier automatiquement les espèces à partir de leurs sons devient alors la condition pour exploiter ces données.

C’est l’objet du jeu BirdCLEF + 2026, qui rassemble pour le Pantanal brésilien des enregistrements focaux, où un individu est ciblé et son chant net au premier plan, et des soundscapes de terrain, où plusieurs espèces se mêlent à un fond sonore dense et qui reflètent les conditions réelles d’usage. La tâche consiste à prédire, par fenêtre de cinq secondes, les espèces présentes ; elle est multi-label et s’évalue par la macro ROC-AUC. Cette mesure correspond à la probabilité que le modèle place une fenêtre où l’espèce est présente au-dessus d’une fenêtre où elle est absente, et elle accorde le même poids à chaque espèce, rare ou commune (0,5 correspond au hasard, 1 à un classement parfait).

Le projet impose de n’entraîner aucun réseau de neurones et de n’utiliser que des modèles tabulaires classiques. Pour y répondre, nous menons en parallèle deux approches comparées tout au long du rapport. La première, la **piste stricte**, ne s’appuie que sur des descripteurs acoustiques calculés à la main, fournis à un modèle classique, sans aucun composant pré-entraîné. La seconde, la **piste hybride**, réutilise un modèle pré-entraîné figé comme extracteur de représentations, sur lesquelles on entraîne ensuite un classifieur classique en point de comparaison. La question est alors de mesurer jusqu’où la piste stricte peut rivaliser avec la piste hybride, et ce que cette comparaison révèle de la difficulté réelle de la tâche. Nous faisons l’hypothèse que les caractéristiques manuelles suffisent à séparer les espèces sur des enregistrements propres, que le modèle pré-entraîné conserve malgré tout l’avantage, surtout sur les espèces rares, et surtout que l’écart entre les enregistrements d’entraînement et les conditions de terrain dégrade fortement la performance réelle, au point qu’une validation menée sur les seuls focaux la surestime.

2 Analyse des données

Le corpus comporte 35 549 enregistrements focaux pour 234 espèces cibles, et 10 658 soundscapes dont 66 sont annotés finement, soit 739 fenêtres uniques de cinq secondes étiquetées (le fichier d’annotations liste chaque fenêtre deux fois). Les annotations de soundscapes sont multi-label par construction, plusieurs espèces étant présentes simultanément.

2.1 Composition taxonomique et couverture

Les oiseaux dominent largement le corpus, devant amphibiens, insectes, mammifères et un unique reptile (figure 1a). La macro ROC-AUC sera donc mécaniquement tirée par les oiseaux, ce qui impose de rapporter aussi des performances ventilées par classe. Surtout, la couverture est asymétrique : on a 206 espèces qui disposent d’au moins un focal, mais 28 n’apparaissent que dans les soundscapes, presque toutes des insectes (figure 1b). Un classifieur entraîné sur le seul focal ignore donc 12 % des classes cibles.

Au-delà des classes, la proximité phylogénétique mérite attention : 77 des espèces identifiées (36,8 %) appartiennent à l’un des 28 genres comptant plusieurs espèces, comme *Leptodactylus* (neuf espèces) ou *Synallaxis* (cinq). Or les espèces d’un même genre ont des vocalisations souvent voisines, ces paires constituent des cas de confusion que nous garderons en tête au moment d’analyser les erreurs.




Figure 1 : Composition et couverture. (a) Répartition des 234 espèces par classe taxonomique, dominée par les oiseaux. (b) Couverture des espèces selon leur présence en focal et en soundscape ; les 28 espèces sans aucun focal sont inapprenables par la piste stricte.

2.2 Déséquilibre et métadonnées

La distribution du nombre d'enregistrements par espèce est très inégale, avec un coefficient de Gini de 0,49 (figure 2a). Quatorze espèces comptent moins de cinq enregistrements et quatre un seul, ces dernières étant impossibles à intégrer dans une validation croisée à cinq plis. La concentration par auteur est par ailleurs forte (Gini 0,81, figure 2b), ce qui crée un risque de fuite si la validation ne groupe que par enregistrement puisque le modèle pourrait apprendre la signature d'un contributeur plutôt que celle d'une espèce. Enfin, 12 % des focaux sont déjà multi-label. La note de qualité révèle une autre asymétrie de source : 98,5 % des enregistrements Xeno-Canto sont notés (moyenne 4,07 sur 5), contre aucun pour iNaturalist. Filtrer sur cette note écarterait donc la totalité d'iNaturalist, c'est-à-dire presque toutes les espèces non-oiseaux. Nous y renonçons pour ne pas amputer le corpus de ses classes minoritaires.




Figure 2 : (a) Déséquilibre du nombre d'enregistrements par espèce. (b) Concentration des contributions, qui motive un test de sensibilité au biais auteur.

2.3 Géographie et représentativité spatiale

La répartition géographique révèle un décalage spatial majeur. Si la plupart des focaux proviennent d'Amérique du Sud, le corpus déborde sur le reste du monde (figure 3), et seuls 2,4 % des focaux se situent effectivement dans la zone du Pantanal, la distance médiane à la zone atteignant 1 607 kilomètres (figure 4). Le modèle apprend donc surtout sur des contextes acoustiques éloignés du Pantanal et risque d'apprendre des variantes peu représentatives de la zone à prédire, puisque les animaux peuvent eux aussi avoir des « accents » régionaux.




Figure 3 : Distribution mondiale des 35 549 enregistrements focaux. Le corpus déborde largement de l'Amérique du Sud, ce qui introduit un décalage avec la zone cible.




Figure 4 : Distribution des distances au Pantanal et part des focaux dans la zone cible (seulement 2,4 %), illustrant le domain shift spatial.

2.4 Propriétés audio

Les fichiers sont uniformément en OGG mono à 32 kHz, ce qui dispense de tout rééchantillonnage. Les durées sont très asymétriques (médiane 21 s, de 0,01 s à près de deux heures) avec 7,3 % des focaux qui durent moins de cinq secondes et sont complétés par des zéros pour remplir la fenêtre, tandis que 14 % dépassent une minute. Le niveau sonore varie par ailleurs d'un facteur considérable entre fichiers, dans un rapport de 1 à 55 000 (figure 5a), ce qui impose une normalisation par enregistrement avant extraction. Concrètement, nous ramènonns chaque fichier à un même volume de référence pour que les descripteurs décrivent le chant de l'espèce et non le réglage du micro. Les signatures acoustiques diffèrent également radicalement selon les classes : un enregistrement représentatif de chacune (figure 6) montre des harmoniques structurées et modulées chez les oiseaux, une large bande chez les amphibiens et une bande étroite très dense chez les insectes, tandis qu'un exemple détaillé (figure 5b) illustre la richesse spectrale d'une vocalisation isolée. Cette diversité justifie d'extraire des descripteurs variés plutôt qu'une famille unique : chaque famille ne capte qu'une facette du son (la hauteur et les MFCC pour les chants modulés des oiseaux, les descripteurs spectraux pour la bande étroite des cigales, les descripteurs temporels pour les cris brefs), si bien que les combiner garantit que chaque classe dispose d'au moins un descripteur qui la caractérise. Enfin, 312 fichiers au signal quasi nul sont identifiés et exclus.




Figure 5 : (a) Niveau sonore par classe, justifiant la normalisation par fichier. (b) Mel-spectrogramme d'un exemple, illustrant la diversité des signatures acoustiques.




Figure 6 : Un enregistrement représentatif par classe taxonomique (forme d'onde à gauche, mel-spectrogramme à droite). La diversité des signatures est nette : harmoniques structurées et modulées chez les oiseaux, énergie en large bande chez les amphibiens, bande étroite très dense et quasi continue chez les insectes (cigales), profils encore distincts chez le mammifère et le reptile.

2.5 Soundscapes et domain gap

Dans les soundscapes annotés, la moitié des fenêtres de cinq secondes contiennent au moins quatre espèces audibles en même temps, d'où la décision de traiter le problème en multi-label. Ils ne couvrent toutefois qu'une part réduite du problème, puisque sur les 234 espèces cibles, 75 seulement apparaissent dans le soundscape annoté, si bien que la performance réelle des 159 autres restera inconnue. Plusieurs espèces fréquentes y sont en outre dépourvues de focal (figure 7b).

La comparaison directe des deux domaines mesure ce que nous appelons le *domain gap*, c'est-à-dire

l'écart entre les sons sur lesquels le modèle est entraîné (les focaux) et ceux qu'il rencontrera vraiment (les soundscapes). C'est le décalage central du projet, et il se mesure concrètement. Sur un échantillon de mille fenêtres (cinq cents par domaine), quatre descripteurs bas niveau, à savoir l'énergie (RMS), le centroïde spectral, le taux de passage par zéro et l'entropie spectrale, diffèrent tous de façon écrasante entre focal et soundscape (test de Mann-Whitney, $p < 0,001$ pour chacun ; figure 9a). L'écart est parfois contre-intuitif. Le soundscape est environ quatre fois plus fort en énergie médiane que le focal (0,106 contre 0,026), parce que les enregistreurs de terrain captent à pleine échelle sans étape éditoriale, et son centroïde spectral est supérieur de 30 % (5173 contre 4014 Hz), reflet des cigales et du bruit ambiant haute fréquence. Une projection en composantes principales, qui résume les nombreux descripteurs en deux axes pour les visualiser sur un plan, sépare nettement les deux domaines (figure 9b), et les mel-spectrogrammes comparés rendent le gap tangible (figure 8).

Ce constat oriente deux choix. D'abord, la normalisation par fichier corrige l'écart d'échelle sonore mais non la différence de composition fréquentielle, qui est propre au domaine cible. Des descripteurs comme le centroïde séparent davantage les domaines que les espèces, ce qui nous conduit à privilégier les coefficients cepstraux (MFCC), plus robustes à ce décalage. Ensuite, un modèle évalué en validation croisée sur le focal mais appliqué au soundscape voit son score surestimé, d'où la nécessité d'un jeu held-out de soundscapes.




Figure 7 : Soundscapes. (a) Volume et couverture annotative par site. (b) Espèces les plus fréquentes en soundscape, en rouge celles sans aucun focal.

2.6 Des observations aux décisions

Chacune des conclusions de l'exploration, croisée avec les contraintes pratiques du projet (cadre temporel, une machine à 8 Go de mémoire, aucun réseau de neurones entraîné), nous a conduits à une décision concrète, résumée dans le tableau 1. C'est ce fil qui relie l'analyse des données à la méthode décrite ci-après, puis aux expériences de la section 4.




Figure 8 : Domain gap focal contre soundscape : mel-spectrogrammes comparés. Les trois premières lignes sont des fenêtres focales (espèce au premier plan, fond propre), les trois dernières des fenêtres soundscape (énergie étalée sur tout le spectre, plusieurs sources superposées).




Figure 9 : Domain gap focal contre soundscape (suite). (b) Quatre descripteurs bas niveau, tous significativement différents entre focal et soundscape. (c) Projection en composantes principales séparant nettement les deux domaines.

Table 1 : Fil conducteur : de chaque observation de l’exploration découle une décision méthodologique, parfois arbitrée par les contraintes de temps et de matériel.

Observation (section 2)	Décision qui en découle
Niveau sonore très variable entre fichiers	Normalisation RMS par enregistrement avant extraction
312 fichiers au signal quasi nul	Exclusion de ces fichiers
12 % des focaux et tous les soundscapes multi-label	Entraînement multi-label, un classifieur par espèce
28 espèces sans aucun focal	Restriction de l’entraînement aux 206 espèces apprenables
Fort déséquilibre + concentration par auteur	Validation croisée groupée par fichier et stratifiée
Domain gap focal/soundscape marqué (ACP, Mann-Whitney)	Held-out soundscape comme juge final, et essais de pseudo-labeling et d’augmentation
Centroïde et ZCR séparent les domaines plus que les espèces	Préférence aux coefficients cepstraux (MFCC), plus robustes au domain gap
Genres à plusieurs espèces, chants voisins	Cas de confusion anticipés, ciblés dans l’analyse d’erreurs
Diversité des signatures (oiseaux, insectes...)	Représentation à 969 caractéristiques + comparaison à Perch
Calendrier court, mémoire limitée	Réglage et comparaison des modèles sur 10 espèces, passage à l’échelle complète du seul meilleur de chaque piste

Des figures complémentaires d’exploration figurent en annexe A.

3 Méthode proposée

3.1 Découpage temporel : la fenêtre de cinq secondes

La métrique de BirdCLEF impose une prédiction par fenêtre de cinq secondes, et le modèle pré-entraîné Perch attend lui aussi une entrée de cinq secondes. Nous adoptons des fenêtres non recouvrantes : un focal de quinze secondes donne trois fenêtres consécutives. Pour borner le temps de calcul sur la machine de développement (Mac M1, 8 Go), nous limitons l’extraction aux trois premières fenêtres de chaque focal, soit les quinze premières secondes, portion qui contient en pratique l’essentiel de la vocalisation ciblée, les enregistrements focaux placent généralement l’espèce d’intérêt au début. Cela ramène le corpus d’entraînement à 44 855 fenêtres sur 206 espèces, volume tenable dans nos limites.

3.2 Caractéristiques et représentations

La piste stricte représente chaque fenêtre de cinq secondes par 969 caractéristiques réparties en six familles : temporelles, spectrales, coefficients cepstraux et leurs dérivées, statistiques mel, indices bioacoustiques, et hauteur. Ce choix répond à la diversité des signatures observée durant l’EDA. La piste hybride remplace cette ingénierie par les embeddings de Perch [2], un réseau pré-entraîné par Google sur un grand corpus de chants d’oiseaux. Ces embeddings sont les vecteurs de 1280 nombres par lesquels le modèle résume chaque fenêtre. Perch est utilisé strictement figé, et seul un classifieur classique est appris par-dessus.

3.3 Rappel sur les classifieurs employés et justification

Nous comparons quatre familles de classifieurs tabulaires, retenues pour leur simplicité et leur interprétabilité, conformément à la contrainte du projet. Trois d’entre elles reposent sur l’*arbre de décision*, une suite de tests successifs sur les descripteurs (« telle valeur dépasse-t-elle tel seuil ? ») qui aboutit à une prédiction. Le *gradient boosting*, implémenté par LightGBM et XGBoost, additionne de nombreux arbres courts construits l’un après l’autre, chacun corrigeant les erreurs des précédents. La *forêt aléatoire* suit la

logique inverse puisqu'elle entraîne des arbres indépendants sur des sous-échantillons aléatoires et moyenne leurs prédictions, ce qui la rend stable et peu sujette au surapprentissage. La *régression logistique*, enfin, n'emploie pas d'arbres mais combine linéairement les descripteurs pour séparer présence et absence d'une espèce ; elle se révèle particulièrement adaptée aux embeddings denses de Perch.

Ces modèles s'appuient sur deux représentations aux fondements distincts : d'un côté les coefficients cepstraux issus du traitement de la parole [1] et les indices bioacoustiques [4], qui composent les caractéristiques manuelles de la piste stricte, de l'autre les modèles pré-entraînés comme BirdNET [3] ou Perch, qui fournissent les embeddings de la piste hybride.

Tous les modèles adoptent une stratégie un-contre-tous : un classifieur binaire par espèce. Ce choix est aligné sur la métrique macro, qui évalue chaque espèce indépendamment, et permet de gérer par classe le fort déséquilibre.

3.4 Protocole de validation

Un découpage entraînement/validation simple est insuffisant ici, pour deux raisons. Plusieurs fenêtres d'un même enregistrement partageant un contenu quasi identique, les répartir de part et d'autre crée une fuite qui gonfle le score, et le déséquilibre des espèces fait qu'un découpage aléatoire peut priver un pli de toute espèce rare. Nous utilisons donc une validation croisée à cinq plis, qui découpe les données en cinq parts, entraîne le modèle sur quatre et l'évalue sur la cinquième en faisant tourner ce rôle, le tout groupé par enregistrement et stratifié par espèce. La fuite évitée a été mesurée puisque passer d'un découpage non groupé à groupé fait chuter le score d'environ 0,04. Comme la validation croisée porte sur le focal alors que la cible est le soundscape, nous réservons en outre un jeu held-out de soundscapes annotés, jamais vu à l'entraînement, qui fournit la mesure de référence.

3.5 Décisions d'entraînement et d'évaluation

Au-delà des choix déjà déduits de l'exploration et résumés dans le tableau 1, trois décisions méthodologiques conditionnent les résultats.

Encodage multi-label et pondération. La vérité terrain liste plusieurs espèces par fenêtre, séparées par un point-virgule. Nous la transformons en une matrice binaire de présence, une colonne par espèce, sur laquelle agit la stratégie un-contre-tous décrite plus haut. Chaque classifieur binaire reçoit en outre une pondération des classes inversement proportionnelle à leur fréquence (*class_weight* équilibré), pour que les espèces rares ne soient pas noyées sous l'abondance d'exemples négatifs.

Un classifieur par piste. Le classifieur retenu diffère d'une piste à l'autre. Côté strict, LightGBM (gradient boosting) l'emporte sur des caractéristiques manuelles hétérogènes. Côté hybride, c'est la régression logistique L2 qui domine sur les embeddings : ces vecteurs de 1280 dimensions sont déjà presque linéairement séparables, et un modèle linéaire y généralise mieux qu'un boosting, plus prompt au surapprentissage. Ce choix suit la nature de la représentation, et la comparaison empirique de la section 4 le confirmera.

Deux seuils d'évaluation. Sur le held-out, beaucoup d'espèces ne comptent qu'une poignée de positifs, rendant leur ROC-AUC très instable. Nous rapportons donc deux agrégats : sur toutes les espèces évaluables (au moins un positif, 47 espèces) et sur les seules espèces à au moins vingt positifs (18 espèces), statistiquement plus fiables. Lire les deux évite de conclure sur du bruit.

4 Résultats

Nous présentons les résultats dans l'ordre où ils ont été construits : d'abord la mise en place progressive de la piste stricte et la comparaison des classifieurs, puis le réglage des hyperparamètres, ensuite la confrontation

au held-out qui révèle le domain gap, et enfin des métriques complémentaires. Sauf mention contraire, tous les scores sont des macro ROC-AUC.

4.1 Comparaison des classifieurs

Nous construisons la piste stricte par étapes, en vérifiant à chaque ajout que le score progresse. Le point de départ est une *baseline*, un modèle minimal qui sert de référence basse : un seul classifieur entraîné sur dix espèces et 26 coefficients cepstraux, qui atteint 0,7469. En enrichissant la représentation jusqu’aux 969 caractéristiques, le score monte à 0,8981 lorsqu’on évalue sur un simple partage entraînement/test, mais retombe à 0,8632 sous validation croisée à cinq plis. Ce second chiffre est le plus fiable, car il moyenne le score sur cinq découpages différents au lieu d’un seul, et c’est sur ce protocole que le tableau 2 compare les cinq classifieurs.

Table 2 : Macro ROC-AUC en validation croisée à cinq plis sur caractéristiques manuelles (sous-ensemble de dix espèces).

Modèle	Macro ROC-AUC	Écart-type
LightGBM optimisé	0,8869	0,0236
XGBoost	0,8732	0,0219
Forêt aléatoire	0,8642	0,0245
Régression logistique L2	0,8636	0,0092
Régression logistique L1	0,8580	0,0142

La hiérarchie est conforme aux observations habituelles sur données tabulaires. Le gradient boosting domine, suivi de près par la forêt aléatoire et la régression logistique. Cette dernière, pourtant linéaire, atteint presque le niveau de LightGBM avec une variance plus faible, ce qui suggère que les caractéristiques encodent déjà une information séparable. L’amplitude réduite des scores indique que le choix du modèle n’est pas vraiment un facteur limitant.

Cette comparaison des cinq classifieurs a été menée sur un sous-ensemble de dix espèces, par souci de temps de calcul. Étant donné les contraintes matérielles et le calendrier du projet, nous n’avons pas réentraîné l’ensemble des modèles sur la totalité des données ni sur le held-out : seul le meilleur classifieur de la piste stricte, LightGBM, a été porté à l’échelle complète (206 espèces) et sur le held-out, et de même la régression logistique a été retenue côté embeddings.

4.2 Réglage et analyse des hyperparamètres

Les hyperparamètres de LightGBM ont été optimisés par recherche bayésienne, une méthode qui privilégie les réglages prometteurs au vu des essais précédents plutôt que d’explorer au hasard, sur cinquante essais évalués chacun par la validation croisée complète à cinq plis. Sept hyperparamètres ont été explorés, dont le réglage retenu est le suivant : taux d’apprentissage 0,032, nombre de feuilles 52, échantillons minimaux par feuille 99, fraction de caractéristiques 0,50, fraction d’exemples 0,84, régularisation L2 de 0,0012, et 751 arbres. Ce réglage porte le score à 0,8869, soit un gain de 0,024 par rapport au réglage par défaut, gain légèrement au-dessus du seuil de bruit empirique de 0,02 mesuré entre plis, ce qui rend l’amélioration crédible mais modeste. Faute de temps de calcul, ce réglage optimisé sur le sous-ensemble de dix espèces a été réutilisé tel quel à l’échelle complète, en faisant l’hypothèse que l’optimum se transfère.

La figure 10 mesure le poids de chaque hyperparamètre dans la variation du score, ce qui explique *pourquoi* le gain reste modeste. Le taux d’apprentissage et le nombre d’arbres comptent à eux seuls pour environ 76 %, alors que les autres réglages, dont la régularisation (le frein qui empêche le modèle de trop

coller aux données d'entraînement), pèsent peu. L'essentiel est donc la quantité d'apprentissage, beaucoup de petits arbres plutôt qu'un réglage fin de chacun. Ce résultat est cohérent, car les 969 caractéristiques sont déjà riches et le modèle apprend le principal rapidement, sans réglages sophistiqués pour généraliser. Deux réglages ont par ailleurs atteint le bord de la plage testée, et élargir la recherche pourrait encore gagner un peu sans changer les conclusions.




Figure 10 : Importance des hyperparamètres de LightGBM (analyse de variance fonctionnelle de l'optimisation bayésienne).

4.3 Analyse critique : domain gap et conditions réelles

À grande échelle (206 espèces, validation croisée), le modèle strict atteint 0,8416 et le benchmark Perch 0,9526, soit un écart de 0,111 qui se creuse par rapport au petit sous-ensemble. Mais ces scores portent sur le focal. Évalués sur le held-out de soundscapes, jamais vu, les deux pistes chutent fortement (tableau 3, figure 11). Le tableau donne deux colonnes selon le nombre de fenêtres positives exigé pour qu'une espèce soit comptée, au moins une (47 espèces) ou au moins vingt (18 espèces, dont le score est statistiquement plus sûr puisqu'il repose sur davantage d'exemples). Cette chute est le résultat central du travail, car elle montre que la validation croisée sur le focal surestime nettement la performance réelle sur le terrain. En se limitant aux espèces dont la mesure est la plus fiable, celles qui comptent au moins vingt fenêtres positives, le modèle strict tombe même à peine au-dessus du hasard (0,5754), ses caractéristiques ayant été calibrées sur le son propre des focaux et ne se transposant quasiment pas aux soundscapes bruités. L'écart en faveur de Perch, modéré sur le focal, s'accroît donc en conditions réelles, ce qui confirme à la fois l'avantage attendu du modèle pré-entraîné et l'ampleur du décalage entre données d'entraînement et terrain.

Table 3 : Macro ROC-AUC en validation croisée focale et sur le held-out soundscape, par nombre minimal de positifs requis.

Piste	CV focal (206 esp.)	Held-out (≥ 1 , 47 esp.)	Held-out (≥ 20 , 18 esp.)
Benchmark Perch	0,9526	0,7460	0,7721
Livrable strict	0,8416	0,6104	0,5754




Figure 11 : Chute des scores entre validation croisée focale et held-out soundscape, pour les deux pistes : visualisation du domain gap.

4.4 Métriques complémentaires

La macro ROC-AUC mesure surtout la qualité du *classement* des fenêtres, mais elle peut masquer la difficulté réelle quand une espèce est rare, car une espèce présente dans dix fenêtres sur 739 n’a qu’environ 1 % de positifs. Nous la complétons donc par trois mesures sur le held-out (tableau 4). L’*Average Precision* regarde si les rares fenêtres réellement positives se retrouvent en tête du classement trié par confiance, et est plus sévère que le ROC-AUC lorsque les positifs sont rares. La précision, le rappel et le score F1 sont quant à eux calculés à un seuil de décision fixé à 0,5. La précision est la part de bonnes réponses parmi les fenêtres déclarées positives, le rappel la part de positifs effectivement retrouvés, et le F1 leur compromis.

Table 4 : Métriques complémentaires sur le held-out soundscape (espèces à ≥ 1 positif, sauf AP_{20} à ≥ 20). P, R et F1 au seuil 0,5.

Piste	ROC-AUC	$AP_{\geq 1}$	$AP_{\geq 20}$	Précision	Rappel	F1
Benchmark Perch	0,7460	0,2921	0,4368	0,3810	0,1013	0,1177
Livrable strict	0,6104	0,1569	0,2378	0,0668	0,0702	0,0455

L’écart entre les deux pistes ne se limite pas au ROC-AUC. Il est même plus marqué en Average Precision, où Perch atteint 0,29 contre 0,16 pour la stricte, et il se retrouve sur la précision au seuil 0,5. Quand Perch annonce une espèce, il a raison environ une fois sur trois (0,38), là où la piste stricte n’a raison qu’une fois sur quinze (0,067). Les valeurs de précision et de rappel restent faibles pour les deux pistes, mais cela vient surtout du seuil de 0,5, trop élevé pour des positifs aussi rares, qui pousse le modèle à ne presque jamais déclarer une espèce présente. Le classement lui-même n’est pas en cause, puisque le ROC-AUC, qui ne dépend d’aucun seuil, reste correct ; ce qui manque, c’est un seuil de décision calibré espèce par espèce, un peu hors du cadre de ce travail. Pour comparer les modèles, nous nous appuyons donc sur le ROC-AUC et l’Average Precision, qui ne dépendent d’aucun seuil.

5 Extensions et analyses complémentaires

5.1 Comparaison avec un modèle pré-entraîné

La piste hybride utilise Perch comme une boîte noire, en gardant le modèle pré-entraîné gelé et en entraînant seulement un classifieur classique sur les vecteurs qu’il produit. Sans entraîner aucun réseau, elle

bat la piste stricte sur tous les plans, et sur le held-out cette dernière n'atteint qu'environ 80 % de son niveau.

On note au passage un renversement entre les deux représentations. Sur les embeddings de Perch, la régression logistique fait mieux que LightGBM en validation croisée (0,9655 contre 0,9579), alors que sur les caractéristiques manuelles c'était LightGBM qui dominait (tableau 2). Les embeddings sont déjà bien structurés, si bien qu'un modèle linéaire suffit à séparer les espèces, tandis que les descripteurs manuels demandent un modèle qui combine les variables de façon non linéaire.

5.2 Réduction du domain gap par pseudo-labeling

Un premier levier pour réduire le domain gap est le pseudo-labeling. On se sert de notre meilleur modèle pour étiqueter automatiquement les soundscapes non annotés, on ne garde que les prédictions où il est très sûr de lui (probabilité supérieure à 0,9), puis on réentraîne en ajoutant ces nouveaux exemples, cette fois issus du terrain. Le seuil élevé évite d'injecter trop d'erreurs, et on plafonne à cent fenêtres par espèce pour qu'une espèce très présente n'écrase pas les autres.

Le résultat dépend de la piste (tableau 5). La piste stricte progresse beaucoup, de 0,5754 à 0,7004 sur les espèces les mieux mesurées, parce que ces exemples de terrain lui apportent enfin ce qui lui manquait. La piste Perch, déjà bonne, recule un peu, car les quelques erreurs des pseudo-labels la perturbent plus qu'elles ne l'aident. Les deux finissent autour de 0,70. Le même outil renforce donc un modèle faible et fragilise un modèle déjà fort.

Table 5 : Effet du pseudo-labeling sur le held-out (macro ROC-AUC).

	Held-out (≥ 1)	Held-out (≥ 20)
Strict (référence)	0,6104	0,5754
Strict + pseudo-labeling	0,6562	0,7004
Perch (référence)	0,7460	0,7721
Perch + pseudo-labeling	0,7140	0,7060

5.3 Réduction du domain gap par augmentation de bruit ambiant

Le second levier s'attaque au domain gap autrement. On rend artificiellement les fenêtres focales plus proches du terrain en y mélangeant un peu de bruit ambiant prélevé dans un soundscape (focal augmenté = $\text{normalise}(\text{focal}) + 0,5 \cdot \text{normalise}(\text{bruit})$), puis on réentraîne sur ces fenêtres bruitées. Pour que la comparaison reste juste, la piste Perch est réévaluée sur exactement le même périmètre, les mêmes trois fenêtres par fichier.

Les résultats sont décevants (tableau 6). Le gain est minime pour la piste stricte (+0,015) et l'augmentation dégrade même légèrement Perch (−0,022). Le plus probable est que ce bruit ajouté à la main ressemble mal aux vrais soundscapes, où la difficulté vient surtout de plusieurs espèces qui se superposent et de conditions d'enregistrement différentes, pas d'un simple fond sonore en plus. Pour Perch, dont les descripteurs sont déjà robustes, ce bruit revient surtout à abîmer le signal d'entrée. Contrairement au pseudo-labeling, cette méthode ne s'attaque donc pas à la vraie cause du décalage.

Table 6 : Effet de l’augmentation par bruit ambiant sur le held-out (macro ROC-AUC). La piste Perch est comparée à périmètre identique (trois fenêtres).

	Held-out (≥ 1)	Held-out (≥ 20)
Strict (référence)	0,6104	0,5754
Strict + augmentation	0,6143	0,5904
Perch (3 fenêtres, réf.)	0,7353	0,7443
Perch + augmentation	0,7119	0,7225

5.4 Analyse des cas d’erreurs par espèce

Le ROC-AUC par espèce sur le held-out (figure 12) confirme la domination globale de Perch : sur les 47 espèces évaluable, Perch fait mieux que la piste stricte dans 36 cas. Mais la dispersion est forte et révèle des régimes distincts (tableau 7). Sur les espèces où Perch écrase la stricte (par exemple **bafcur1** : 0,11 contre 0,84), il s’agit typiquement d’oiseaux dont les vocalisations, propres dans le focal, sont noyées dans le fond sonore du soundscape. Les caractéristiques manuelles, calibrées sur le signal propre, ne les retrouvent plus, là où l’embedding pré-entraîné reste robuste.




Figure 12 : ROC-AUC held-out par espèce, piste stricte (abscisse) contre Perch (ordonnée). Au-dessus de la diagonale, Perch est meilleur (36 espèces sur 47). Quelques contrastes extrêmes sont annotés.

À l’inverse, onze espèces sont mieux prédites par la piste stricte, parfois très nettement (**strher2** : 0,99 contre 0,24 ; **ruther1** : 0,88 contre 0,24). Deux explications se conjuguent sans doute. D’une part, Perch a été entraîné sur des vocalisations d’*oiseaux*, si bien que les espèces non aviaires du corpus, notamment les insectes (les codes numériques comme **65377**, où Perch tombe à 0,04), sortent de son domaine de compétence, alors que leurs stridulations à bande étroite sont bien captées par des descripteurs spectraux manuels. D’autre part, certaines espèces à la signature très marquée, peu sujettes à confusion, sont déjà bien séparées par les caractéristiques manuelles. Cette hétérogénéité nuance l’idée d’une supériorité uniforme de Perch et justifie, en perspective, un système hybride choisissant la piste selon le type d’espèce.

Table 7 : Contrastes par espèce sur le held-out (ROC-AUC). À gauche, les espèces où Perch domine ; à droite, celles où la piste stricte domine.

Perch $\gg$ stricte			Stricte $\gg$ Perch		
Espèce	Strict	Perch	Espèce	Strict	Perch
bafcur1	0,11	0,84	strher2	0,99	0,24
grekis	0,40	0,98	ruther1	0,88	0,24
sibtan2	0,42	0,97	plcjay1	0,91	0,64
23158	0,38	0,92	65377	0,60	0,04
chvcon1	0,29	0,79	bunibi1	0,30	0,10

6 Conclusion

Ce travail a mis en place et évalué une chaîne complète de classification multi-label de sons d'espèces, comparant des caractéristiques acoustiques extraites à la main à des embeddings pré-entraînés, sous la contrainte de n'entraîner aucun réseau de neurones. En validation croisée sur les enregistrements focaux, la piste stricte atteint une macro ROC-AUC de 0,84 et la piste hybride 0,95. Évaluées sur le held-out de soundscapes, représentatif des conditions de terrain, les deux pistes reculent nettement, à 0,61 et 0,75 respectivement, et la piste stricte se rapproche du niveau du hasard sur les espèces les mieux mesurées.

Ce recul quantifie le domain gap entre enregistrements focaux d'entraînement et soundscapes de terrain, qui constitue le principal résultat de l'étude, car un score obtenu en validation croisée sur le focal sures-time fortement la performance réelle. Parmi les deux stratégies d'atténuation examinées, le pseudo-labeling améliore sensiblement la piste stricte, de 0,58 à 0,70 sur les espèces les mieux mesurées, tandis que l'augmentation par bruit ambiant reste sans effet notable. Ces résultats soulignent que la fiabilité d'une évaluation dépend de la représentativité des données sur lesquelles elle repose.

Plusieurs prolongements seraient possibles. Étendre la comparaison des classifieurs à l'ensemble des 206 espèces et au held-out, et non au seul sous-ensemble de dix espèces, consoliderait le choix des modèles. On pourrait également calibrer un seuil de décision par espèce pour les métriques à seuil. L'analyse par espèce suggère par ailleurs un système hybride qui retiendrait l'une ou l'autre piste selon le type de signal, les descripteurs manuels captant mieux les insectes que Perch. Enfin, réduire davantage le domain gap demanderait des soundscapes annotés supplémentaires, qui couvriraient les espèces aujourd'hui absentes du held-out, ou une augmentation plus fidèle aux conditions de terrain que le simple ajout de bruit.

7 Bibliographie

- [1] Steven DAVIS et Paul MERMELSTEIN. « Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences ». In : *IEEE Transactions on Acoustics, Speech, and Signal Processing* 28.4 (1980), p. 357-366.
- [2] Jenny HAMER et al. « Perch : A general-purpose pre-trained bioacoustic model ». In : *arXiv preprint* (2023). Référence à vérifier et compléter avant rendu.
- [3] Stefan KAHL, Connor M. WOOD, Maximilian EIBL et Holger KLINCK. « BirdNET : A deep learning solution for avian diversity monitoring ». In : *Ecological Informatics* 61 (2021), p. 101236.
- [4] Jerome SUEUR, Almo FARINA, Amandine GASC, Nadia PIERETTI et Sandrine PAVOINE. « Acoustic indices for biodiversity assessment and landscape investigation ». In : *Acta Acustica united with Acustica* 100.4 (2014), p. 772-781.

A Figures complémentaires d'exploration




Figure 13 : Figures complémentaires d'exploration : genres multi-espèces, sources de données, qualité, durées, fichiers défectueux, couverture temporelle et par site. Détails dans le corps du rapport et dans `observations.md`.